

Séance Projet: TRANSFORMATION ET INTÉGRATION DE DONNÉES D'UN FICHIER SOURCE VERS UN FICHIER CIBLE

IUT SD Aurillac

Objectifs:

- | | |
|--|--|
| <ul style="list-style-type: none">— Comprendre et respecter les spécifications pour garantir l'interopérabilité entre systèmes.— Manipuler des structures de données en Python (listes, dictionnaires, Pandas). | <ul style="list-style-type: none">— Développer un programme réalisant des opérations de lecture, transformation et écriture de données.— Documenter le code et les résultats obtenus. |
|--|--|

1 Contexte

Vous travaillez en tant que consultant en intégration de données. Une entreprise souhaite migrer des données d'un système source vers un nouveau système cible. Les fichiers sources sont des fichiers texte au format CSV, et l'objectif est de les transformer pour les adapter à un format attendu par le nouveau système d'information, tout en respectant des spécifications.

Votre mission est de concevoir et développer un programme en Python qui :

1. Lit un fichier source (au format CSV).
2. Transforme les données selon des règles définies.
3. Écrit les données dans un fichier cible au format attendu (CSV avec un autre schéma).

2 Consignes

Le projet peut se faire seul ou à deux.

Vous devez choisir un des deux sujets proposés.

Pour chacun des sujets, vous devez rendre :

- Le code python compréhensible ET documenté (docstrings, commentaires supplémentaires si besoin).
- Un rapport de 2 pages **maximum** expliquant vos choix d'implémentation.
- Les fichiers obtenus grâce à votre script.

Date limite de rendu : le 17 janvier à 23h59.

SUJET 1 : Données hospitalières

L'organisation de santé qui fait appel à vous souhaite analyser les dossiers des patients pour optimiser la gestion des traitements. Ses données sont disponibles dans les fichiers `hospital_data.csv` et `additional_hospital_data.csv`.

Exercice 1 (Corriger les données,)

Commencez par consulter les données fournies, et les nettoyer (via un script python).

1. Reformater les dates de naissance (DOB) et les dates de dernière visite (LastVisit) au format DD/MM/YYYY.
2. Corriger les noms de diagnostics pour qu'ils soient uniformes (majuscule systématique).
3. Complétez les valeurs manquantes par une valeur cohérente de votre choix.

□

Exercice 2 (Compléter les données,)

1. Ajouter une colonne Age calculée à partir de la date de naissance.
2. Ajouter une colonne Statut indiquant si un patient est : Sain (diagnostic Healthy), sinon Malade.

□

Exercice 3 (Fusionner les données,)

Utiliser les fichiers `hospital_data.csv` et `additional_hospital_data.csv` et fusionner leurs données en supprimant les doublons sur la base des colonnes PatientID.

□

Exercice 4 (Créer un log des modifications,)

Générer un fichier `modifications_log.txt` contenant toutes les modifications effectuées (corrections, ajouts, suppressions).

□

SUJET 2 : Données sur les jeux vidéo

L'entreprise de jeux vidéos qui fait appel à vous souhaite analyser les données de joueurs pour mieux comprendre les comportements et identifier les joueurs engagés. Les données sont disponibles dans les fichiers `videogame_data.csv` et `additional_videogame_data.csv`.

Exercice 5 (Corriger les données,)

Commencez par consulter les données fournies, et les nettoyer (via un script python) si besoin.

1. Identifier et corriger les erreurs de format dans les noms de jeux (majuscule systématique).
2. Rectifier les dates mal formatées (`LastLogin`), qui doivent être au format `DD/MM/YYYY`.
3. Traiter les valeurs manquantes dans la colonne `Score` en les remplaçant par une valeur cohérente de votre choix.

□

Exercice 6 (Compléter les données,)

Ajouter une colonne `Performance` qui évalue les joueurs :

1. Élevée si le score est supérieur à 7000.
2. Moyenne si le score est entre 4000 et 7000.
3. Faible si le score est inférieur à 4000.

□

Exercice 7 (Fusionner les données,)

Utiliser les fichiers `videogame_data.csv` et `additional_videogame_data.csv` et fusionner les données en supprimant les doublons sur la base des colonnes `Username` et `Game`.

□

Exercice 8 (Créer un log des modifications,)

Générer un fichier `modifications_log.txt` contenant toutes les modifications effectuées (corrections, ajouts, suppressions).

□