

SAE 3-03 – Description et prévision de données temporelles

Rapport d'analyse

BUT Science des données
IUT d'Aurillac

Mouhammad Moustapha NDIAYE
Remmide ABDALLAH
Sérigne FALL
Ibrahima TOURE

Année universitaire 2025

Prof Mme SOHIER Emilie

Contents

1	Introduction	3
2	<i>Comment éliminer l'effet de l'heure dans les mesures du poids</i>	4
3	<i>Comment estimer la masse grasse réelle au cours du régime ?</i>	5
4	<i>La série présente-t-elle une cassure structurelle ?</i>	5
5	<i>Comment modéliser l'évolution avant et après la cassure ?</i>	6
6	<i>Conclusion générale</i>	7

1 Introduction

Ce rapport d'étude est la réalisation de ***SAE concernant les données de série chronologique ou temporelles*** : afin de produire cet ouvrage, nous nous sommes appuyés sur les méthodes vues en cours ainsi que sur celles utilisées lors des séances de Travaux Pratiques (TP).

Notre approche consiste à suivre les différentes problématiques identifiées à partir des questions proposées dans les étapes de résolution du projet. Chaque problématique présentée dans ce rapport sera accompagnée d'une interprétation ou d'une conclusion, ce qui nous permettra d'atteindre l'objectif final de cette étude.

2 Comment éliminer l'effet de l'heure dans les mesures du poids

Pour répondre à cette problématique, il a d'abord été nécessaire de réaliser un prétraitement approprié des données. L'étape la plus importante a été la **conversion des horaires au format numérique** (création de la variable **HeureNum**). Sans cette transformation, il n'aurait pas été possible d'appliquer correctement le lissage LOESS, qui exige une variable numérique continue pour modéliser la variation intra-journalière du poids.


Le premier graphique obtenu avec le LOESS présentait une courbe totalement irrégulière, composée de segments qui se croisaient et formaient une sorte de *"toile d'araignée"*. Cette forme rendait impossible toute interprétation de la variation moyenne du poids au cours d'une journée.

Ce problème ne venait pas du modèle LOESS lui-même, mais de l'ordre dans lequel les points étaient tracés. Les heures n'étaient pas triées : les enregistrements apparaissaient dans un ordre mélangé (par exemple 9h30, puis 18h45, puis 7h30, etc.). Lors du traçage, R reliait donc les points dans cet ordre incorrect, produisant une courbe qui se repliait sur elle-même et devenait illisible.

La solution a consisté à **trier les données selon l'heure numérique** avant de tracer la courbe. Une fois les observations ordonnées du plus petit au plus grand horaire, la courbe obtenue était fluide, continue et interprétable. Dans ces conditions, le lissage LOESS représente correctement la variation moyenne du poids au cours d'une journée.

L'effet de l'heure sur les mesures du poids peut être efficacement éliminé à condition de réaliser un prétraitement rigoureux des données. La transformation des horaires en variable numérique et le tri préalable des observations sont des étapes clés pour obtenir un lissage LOESS interprétable. Une fois ces conditions respectées, la variation intra-journalière du poids est correctement modélisée, ce qui permet de corriger les mesures et de disposer d'une série cohérente pour l'analyse de la masse grasse et de son évolution dans le temps.

Lissage du poids dans la journée par LOESS



3 *Comment estimer la masse grasse réelle au cours du régime ?*

Après avoir corrigé le poids de la seconde phase afin de supprimer les variations dues à l'heure de la journée, la masse grasse en kilogrammes a été calculée en multipliant le poids corrigé par le pourcentage de masse grasse (exprimé en proportion). Cette étape permet d'obtenir, pour chaque jour de la phase deux, une estimation fiable de la masse grasse réelle du sujet.


Les résultats montrent une évolution caractéristique : la masse grasse augmente progressivement au début de la période, passant d'environ 34 kg à un maximum proche de 38 kg autour du premier avril. Par la suite, on observe une diminution nette, la masse grasse redescendant vers 32 kg dans les derniers jours. Cette courbe reflète les variations réelles de la composition corporelle indépendamment des fluctuations du poids liées aux horaires des pesées.

Ce calcul est essentiel car il permet d'isoler la tendance propre de la masse grasse et d'interpréter l'évolution physique du sujet de manière fiable, sans être influencé par le moment de la journée où les pesées ont été effectuées.

L'estimation de la masse grasse réelle repose sur la correction préalable du poids et sur l'utilisation du pourcentage de masse grasse. Cette méthode permet d'obtenir une série temporelle fiable décrivant l'évolution de la composition corporelle du sujet au cours du régime. Les résultats montrent clairement une phase d'augmentation suivie d'une diminution marquée de la masse grasse, ce qui justifie la poursuite de l'analyse afin de vérifier l'existence d'une éventuelle cassure structurelle dans la dynamique observée.

4 *La série présente-t-elle une cassure structurelle ?*

Au regard de l'évolution de la masse grasse constatée dans la section précédente. Cette évolution met en évidence un changement réel dans la dynamique corporelle, ce qui nous a incités à vérifier cette hypothèse à l'aide du test de cassure de *Chow*.



Le test de cassure a été appliqué à la série de masse grasse corrigée de la phase deux. Le graphique des $\log(p\text{-values})$ montre un minimum marqué à l'index 10, correspondant au 2 avril. Cet index minimise la $p\text{-value}$ du test de Chow, indiquant une rupture structurelle significative dans l'évolution de la masse grasse.

Cette analyse confirme que la chute observée juste après le premier avril n'est pas une fluctuation aléatoire, mais bien une cassure réelle dans la dynamique corporelle du sujet. Ce changement brutal est donc statistiquement fondé et marque une transition nette dans l'évolution de la composition corporelle au cours de la seconde phase.

Le test de Chow valide statistiquement l'existence de cette rupture, montrant que l'évolution de la masse grasse avant et après cette date ne peut pas être décrite par un seul modèle. Cette cassure justifie la mise en place de modèles distincts pour les périodes précédant et suivant la rupture, afin de décrire correctement la dynamique de la masse grasse et de réaliser des prévisions pertinentes.

5 *Comment modéliser l'évolution avant et après la cassure ?*

Afin d'estimer la quantité de masse grasse que le sujet aurait perdue si le régime avait duré trois jours de plus, il a été nécessaire de modéliser l'évolution de la masse grasse en tenant compte de la cassure identifiée précédemment. La page Wikipedia consacrée au : **Test de Chow** montre clairement la démarche à suivre : une fois le point de rupture déterminé, il faut ajuster deux modèles linéaires sur les deux segments définis par cette cassure. Ainsi, nous avons appliqué :

- une régression linéaire sur le segment 1 (avant cassure),
- une régression linéaire sur le segment 2 (après cassure).


Les prévisions doivent être effectuées à partir du second modèle, puisqu'il représente la dynamique active à la fin du régime. En projetant ce modèle sur les trois jours suivants, nous obtenons les valeurs suivantes :

Warning: le package 'knitr' a été compilé avec la version R 4.5.2

Table 1: Prévisions de masse grasse sur 3 jours

Jour	Masse_grasse_kg
Jour +1	31.36
Jour +2	30.75
Jour +3	30.14

La modélisation segmentée avant et après la cassure permet de représenter fidèlement la dynamique réelle de la masse grasse. L'utilisation du modèle linéaire ajusté après la cassure fournit des prévisions cohérentes et réalistes, montrant que la perte de masse grasse se serait poursuivie de manière significative si le régime avait été prolongé de trois jours, qui est estimée à **1.80 kg**. Cette approche confirme l'intérêt de la détection de cassure structurelle pour améliorer la qualité de la modélisation et la pertinence des prévisions.



6 Conclusion générale

Cette étude avait pour objectif d'analyser et de prévoir l'évolution de données temporelles liées au poids et à la masse grasse d'un sujet dans le cadre d'un régime. À travers une démarche progressive et méthodologiquement rigoureuse, les différentes problématiques ont permis de construire une analyse fiable et interprétable.

Dans un premier temps, le prétraitement des données a permis d'éliminer l'effet de l'heure sur les mesures du poids. La conversion des horaires en variable numérique et l'utilisation d'un lissage LOESS ont montré que les variations intra-journalières pouvaient être correctement modélisées et corrigées, garantissant ainsi la cohérence de la série étudiée.

À partir du poids corrigé, l'estimation de la masse grasse réelle a mis en évidence une évolution non linéaire au cours du régime, caractérisée par une phase d'augmentation suivie d'une diminution marquée. Cette observation a conduit à l'identification d'une cassure structurelle, confirmée statistiquement par le test de Chow, située autour du 2 avril. Cette rupture traduit un changement réel dans la dynamique corporelle du sujet.

Enfin, la modélisation séparée de l'évolution avant et après la cassure a permis d'obtenir des prévisions pertinentes. Le modèle linéaire ajusté après la rupture indique que la perte de masse grasse se serait poursuivie de manière significative si le régime avait été prolongé, avec une estimation d'environ 1.80 kg supplémentaires perdus sur trois jours.