

SAE Collecte, Nettoyage et Visualisation des Monarques de France

Mouhamed Moustapha Ndiaye - Abdallah Remmide - BUT Science des Données

14 mars 2026

Introduction

Ce rapport synthétise notre démarche pour la réalisation de l'**Épisode 1**. Conformément aux consignes, l'objectif était d'extraire des données historiques depuis le site Wikipédia (sans utiliser d'API officielle), de les nettoyer, et de produire un tableau de bord analytique interactif retraçant la généalogie des rois de France.

1 L'Environnement de travail

Avant toute ligne de code, nous avons isolé notre espace de travail en créant un **environnement virtuel** (.venv). Cette étape est primordiale : elle permet d'installer les dépendances du projet (pandas, streamlit, beautifulsoup4) dans un "coffre-fort" local. Cela évite les conflits de versions sur l'ordinateur et garantit que le projet pourra être exécuté sur n'importe quelle machine sans erreur de module introuvable.

2 Collecte des données (Scraping)

Pour acquérir les données, nous avons développé un script Python basé sur BeautifulSoup. Le programme fonctionne en deux temps pour cibler efficacement l'information :

1. Il parcourt le tableau principal de Wikipédia pour lister tous les monarques.
2. Il visite automatiquement le lien de chaque monarque pour extraire spécifiquement son ascendance (Père, Mère) et sa descendance (Enfants) contenues dans l'Infobox latérale.

3 Nettoyage et structuration (Data Cleaning)

Les données extraites étaient brutes et irrégulières. Par exemple, les prénoms étaient souvent fusionnés (ex : « ClovisIer ») ou remplacés par du texte descriptif (« Deux filles »).

Pour rendre ces données exploitables mathématiquement, nous avons eu recours aux **Expressions Régulières (Regex)**. Nous avons créé des règles pour :

- Insérer des espaces entre les mots collés en détectant les lettres majuscules.

- Extraire uniquement l'année de début de règne (au format 4 chiffres) en ignorant les mois.
- Convertir les listes textuelles d'enfants en une variable quantitative (Nombre d'enfants).

Le résultat a été structuré via un *DataFrame* Pandas, puis exporté dans un fichier CSV allégé.

4 Tableau de bord interactif (DataViz)

Pour finaliser l'épisode 1, nous avons construit une application web avec la bibliothèque **Streamlit**. Ce tableau de bord lit notre fichier CSV nettoyé et utilise la bibliothèque **Plotly** pour générer des visualisations interactives. Il propose une frise chronologique temporelle, un palmarès des familles les plus nombreuses, ainsi qu'un explorateur de lignée pour consulter le détail d'un roi précis.

5 Guide d'exécution du projet

Pour tester l'application et visualiser le tableau de bord, voici les commandes à exécuter séquentiellement dans le terminal, depuis le dossier racine du projet :

1. **Activer l'environnement virtuel :**
`.\.venv\Scripts\Activate.ps1`
2. **Lancer l'application web Streamlit :**
`streamlit run app.py`