



SAE 1-03 : Rapport

Procédure d'analyse, graphiques et interprétations

Réalisé par :

Amin Amri
Oussama Laïfi
Pape Moctar Gaye
Fares Benkrouidem
Abdallah Remmide
Erwan-Nelson Fotso Kwayep

Enseignant :

Paul Marie Grollemund

Groupe G

27/12/2024

Année universitaire 2024/2025

Pour commencer, nous allons présenter dans ce rapport une analyse descriptive du tableau de données des anciens étudiants rendant compte des informations importantes.

Nous avons téléchargé le tableau sur l'ENT, l'avons exporté en CSV et importé dans R Studio. Un nettoyage manuel a été effectué pour corriger les incohérences, comme les variations dans le codage des variables qualitatives (ex. 'h', 'homme', 'masculin'). Ces corrections ont permis d'harmoniser les données et de garantir leur exploitabilité. Cette étape a été essentielle pour la suite, car nous travaillons désormais sur une base de données modifiée et corrigée, distincte de celle initialement fournie qui contenait plusieurs erreurs : La nouvelle base de données est nommée "database".

Beaucoup de variables du tableau de données sont au format "chr" c'est-à-dire que les données contiennent des chaînes de caractères et donc R Studio interprète son contenu comme du texte. Ces données sont dans les colonnes des variables quantitatives. Il s'agit de "N/A". Nous avons donc transformé "N/A" en "NA" car cette dernière est une valeur reconnue par R Studio.

Le tableau de données utilisé pour cette étude est composé de 20 variables concernant un échantillon de 54 étudiants. Ces variables incluent des informations quantitatives (âge) et qualitatives (genre, origine). L'objectif de cette analyse est d'explorer ces données en utilisant :

- 1- Des indicateurs numériques tels que la moyenne, la médiane, l'écart-type, etc.
- 2- Des visualisations graphiques afin d'illustrer les tendances et les répartitions.
- 3- Des interprétations des résultats pour mettre en lumière les informations importantes.

Les indicateurs numériques sont calculés sur les variables quantitatives : âge, âge d'entrée, année de naissance, durée du BUT et durée pour trouver un stage. Pour harmoniser les unités, nous avons converti "**duree_SD**" en années et "**stage_duree_pour_trouver**" en mois, cette étape ayant été réalisée manuellement lors du nettoyage des données.

	Moyenne	Variance	Écart_Type	Médiane	Q1	Q3	Min	Max
age	21.666667	2.333333	1.527525	22.0	21	22.50	20.00	23
annee_naissance	2001.400000	2.750000	1.658312	2002.0	2001	2003.00	1996.00	2003
age_entree_SD	18.560000	0.923333	0.960902	18.0	18	19.00	17.00	21
duree_SD	2.040732	0.867522	0.931408	2.0	1	3.00	0.67	5
stage_duree_pour_trouver	2.653500	3.259181	1.805320	2.5	1	4.25	0.46	6

Âge des étudiants : Moyenne de 21,67 ans, avec peu de variations (écart-type 1,53). Les âges vont de 20 à 23 ans, montrant une population homogène.

Année de naissance : Moyenne de 2001,4, majoritairement nés entre 1996 et 2003.

Âge d'entrée : Moyenne de 18,56 ans, variant de 17 à 21 ans, typique d'une entrée après le lycée.


Durée des études : Moyenne de 2,04 ans, avec des cas atypiques allant jusqu'à 5 ans.

Durée pour trouver un stage : Moyenne de 2,65 mois, mais une forte variabilité (0,46 à 6 mois), certains trouvant rapidement, d'autres plus lentement.

En résumé ces données décrivent un groupe homogène sur le plan des âges et de la durée des études, mais une plus grande diversité dans la recherche de stages.

Nous allons maintenant nous intéresser à la répartition de la pertinence du BUT Science des Données pour en analyser les tendances.

La base de données initiale combinait des notes (0 à 10) et des appréciations qualitatives, nécessitant un nettoyage manuel pour homogénéiser les données. Les catégories finales sont : **Très pertinent** (9-10), **Pertinent** (8), **Plutôt pertinent** (7), **Assez pertinent** (6), **Moyennement pertinent** (5), **Peu pertinent** (2-4), et **Pas du tout pertinent** (0-1). Ce processus a permis une analyse cohérente des perceptions.




Ce graphique en barres montre la répartition de la pertinence perçue du BUT Science des Données par les participants, selon différentes catégories :

1. **Plutôt pertinent** : C'est la catégorie la plus représentée, avec un effectif de 7, indiquant que la majorité des répondants trouvent le BUT "plutôt pertinent".
2. **Très pertinent** : Un nombre significatif (environ 4 répondants) considère le BUT comme "très pertinent", montrant une satisfaction élevée parmi certains.

3. **Assez pertinent et pas du tout pertinent** : Ces catégories regroupent chacune environ 3 répondants, montrant des avis partagés entre ces deux extrêmes.
4. **Moyennement pertinent et peu pertinent** : Ces catégories ont les effectifs les plus faibles, indiquant qu'elles sont moins fréquentes dans les réponses.

En résumé, la perception du BUT SD est globalement positive, la plupart des participants le jugeant au moins "plutôt pertinent", bien qu'il existe une diversité d'opinions.


Passons à l'analyse de la répartition des genres dans le BUT Science des Données pour déterminer lequel est le plus représenté. Nous avons représenté cette variable sous forme de diagramme en barre.



L'analyse révèle qu'il y a 43 hommes et seulement 8 femmes dans le BUT Science des Données, montrant une forte représentation masculine.

Abordons maintenant la répartition des spécialités en deuxième année à l'aide d'un diagramme en camembert pour mieux visualiser les choix effectués.


Camembert des options



On constate que la plupart des étudiants en 2eme année font le choix d'aller en EMS. Ce choix peut s'expliquer par le fait que la plupart des étudiants sont en général plus à l'aise dans les matières comme la Statistique et veulent y poursuivre leurs études. De plus, les variables "**matiere_utile**" et "**matiere_facile**" montrent que les statistiques sont bien représentées parmi les matières perçues comme utiles et faciles, ce qui confirme leur attrait pour cette filière.

Nous terminons par l'analyse de la durée observée pour trouver un stage chez les anciens étudiants, une donnée qui peut offrir un aperçu précieux aux nouveaux étudiants en science des données comme nous. Cette analyse est représentée par un boxplot.

Boxplot de la durée pour trouver un stage



On constate que la durée médiane pour trouver un stage est de 2,5 mois, ce qui signifie que la moitié des étudiants trouvent leur stage en 2,5 mois ou moins. Un quart des étudiants (25 %) trouvent leur stage en 1 mois ou moins (1er quartile, Q1), tandis que 75 % d'entre eux trouvent leur stage en 4,25 mois ou moins (3e quartile, Q3).

Le temps minimum enregistré pour trouver un stage est de 0,46 mois, soit environ deux semaines, ce qui reflète des cas exceptionnels où l'opportunité était déjà bien définie. À l'opposé, le temps maximum est de 6 mois, montrant que certains étudiants peuvent rencontrer des difficultés ou des contraintes spécifiques.

La majorité des étudiants trouvent leur stage entre 1 et 4,25 mois, avec une concentration autour de la médiane (2,5 mois). Cependant, la différence entre le minimum (0,46 mois) et le maximum (6 mois) montre qu'il existe des situations variées, allant d'opportunités immédiates à des recherches plus longues et complexes.

En résumé, cette analyse de la base de données des anciens étudiants a mis en évidence les tendances générales et les variations observées sur plusieurs variables. Ces résultats offrent un aperçu précieux de leurs expériences, aidant ainsi les nouveaux étudiants, comme nous, à mieux se préparer et à anticiper les étapes clés de notre parcours.