

Projet pour la SAE 2.03

Régression sur données réelles

Les sujets possibles

Dans le cadre de ce projet, vous pouvez choisir le sujet que vous allez traiter parmi les trois sujets possibles, détaillés ci-dessous :

1. Ce premier sujet contient des données relatives à des **appartements à louer à Aurillac** (hiver 2020), avec des informations comme le quartier, la superficie, le loyer et le nombre de pièces. La problématique pertinente à étudier autour de ces données est de déterminer les facteurs qui sous-tendent le loyer d'un appartement. De plus, il sera possible 1) d'évaluer si les conclusions diffèrent d'un quartier à un autre et 2) d'évaluer la qualité prédictive de votre modélisation en utilisant des informations concernant les appartements des étudiants de la promo.
 2. Pour ce deuxième sujet, il est question d'analyser des informations démographiques de la **Corée du Sud** de 2000 à 2022. Pour cela vous devrez identifier des problématiques d'intérêt, comme par exemple : "quel lien y a-t-il entre divorce et mariage?" ou "quel lien y a-t-il entre divorce et naissance?". Vous pourrez en particulier identifier si les résultats sont différents entre les différentes régions coréenne ou en fonction des années.
 3. Ce dernier sujet concerne les **gains des joueurs de Valorant**, en individuel ou en équipe, et il est question pour ce sujet de faire le lien entre les résultats et les gains. Un travail supplémentaire de collecte de données pourra être une piste pour apporter un angle d'analyse nouveau.
-

Consignes

Pour commencer, vous devez constituer les groupes et vous devez en informer par mail à votre enseignant. Le groupe doit aussi choisir un des trois sujets et en informer l'enseignant. La date limite pour constituer le groupe et choisir le sujet est le **dimanche 18 mai (23h59 au plus tard)**. Les données vous seront partagées durant la semaine du lundi 19 mai, ce qui correspond à la date de début de ce projet.

Votre travail doit donner lieu à un **rapport d'étude** détaillant 1) le sujet du projet, 2) la ou les problématiques que vous avez principalement étudié, 3) les approches que vous avez utilisées ainsi que vos résultats, et 4) une conclusion dans laquelle vous détaillerez vos interprétations. Ce rapport ne doit pas faire plus de 5 pages (sans compter la page de garde et les pages blanches). Il pourra contenir des graphiques, mais avec parcimonie puisqu'aucune annexe ne sera acceptée.

Vous devrez joindre à ce rapport, un **script R** , avec les commandes que vous avez utilisé. Ce script ne doit pas contenir de partie "brouillon" du code. Il doit s'agir d'une version finale de votre code, qui est à utiliser pour retracer l'ensemble des approches utilisées et l'ensemble des résultats obtenus. Des commentaires seront à insérer dans votre code de sorte à rendre possible la lecture de votre code.

L'ensemble des documents (rapport et script R) est à rendre par mail à paul_marie.grollemund@uca.fr avant le **vendredi 20 juin (23h59 au plus tard)**.

Barème

Seront pris en compte pour la notation, les aspects suivants :

- la qualité et la pertinence de votre rapport,
- la réponse apportée à la problématique,
- la pertinence des méthodes utilisées, et
- la qualité de votre code.