

Projet SAE 2.03

Régression sur données réelles

Analyse des loyers à Aurillac

Fall Serigne
Mohamed Ndiaye
Abdallah Remide
Erwan Nelson

Année universitaire 2024-2025



Département Science des Données
IUT d'Aurillac
Université Clermont Auvergne

Encadrant : **(Paul Marie Grollemund)**

1. Introduction

Ce rapport s'inscrit dans le cadre du projet SAE 2.03 intitulé *Régression sur données réelles*. L'objectif de ce projet est d'identifier les facteurs qui influencent le loyer mensuel des logements à Aurillac, à partir d'un jeu de données réel fourni par les enseignants.

Dans cette étude, nous utilisons les outils statistiques étudiés au cours du semestre, notamment les modèles de régression linéaire simple et multiple, pour comprendre et prédire le montant des loyers en fonction de plusieurs variables explicatives : la superficie, le nombre de pièces, et le quartier.

Notre travail s'organise en plusieurs étapes :

- explorer et analyser le jeu de données original (92 logements) ;
- construire différents modèles de régression (simple et multiple) ;
- comparer la qualité prédictive des modèles ;
- tester la robustesse du modèle final à l'aide d'un second jeu de données issu d'une enquête menée auprès d'étudiants de notre promotion ;
- évaluer l'erreur de prédiction et discuter des limites du modèle.

La problématique générale que nous cherchons à résoudre est la suivante :

Quels sont les principaux facteurs qui influencent le loyer mensuel d'un appartement à Aurillac, et dans quelle mesure peut-on le prédire ?

2. Exploration du jeu de données initial

Le jeu de données initial contient **92 logements** situés à Aurillac. Il comporte 4 variables :

- **quartier** : quartier d'Aurillac (variable qualitative) ;
- **superficie** : surface du logement (en m^2) ;
- **loyer** : montant du loyer mensuel (en euros) ;
- **nb_pieces** : nombre de pièces principales.

Toutes les variables sont bien renseignées. Les traitements de base (vérification des types, transformation des quartiers en facteur) ont été réalisés avec R.

2.1 Répartition des loyers

La variable **loyer** varie entre 210 € et 970 €, avec une moyenne d'environ 441 €. La majorité des logements ont un loyer entre 300 € et 500 €, mais quelques cas extrêmes tirent la moyenne vers le haut.




FIGURE 1 – Répartition des loyers à Aurillac

2.2 Influence du quartier sur le loyer

Le quartier peut jouer un rôle sur le prix du loyer. Le boxplot ci-dessous illustre la variabilité des loyers selon les quartiers. On observe que certains quartiers comme République ou Zone Verte présentent des loyers plus élevés en moyenne, tandis que d'autres comme Marmiers n'ont qu'un seul logement représenté.




FIGURE 2 – Loyer selon le quartier

2.3 Corrélation entre superficie et loyer

Enfin, nous avons calculé la corrélation entre la superficie et le loyer. Le coefficient obtenu est de **0,892**, ce qui indique une forte relation linéaire positive. Cela signifie que plus la surface d'un logement est grande, plus son loyer a tendance à être élevé.

3. Construction des modèles

L'objectif principal de ce projet est de modéliser le loyer d'un logement à Aurillac à partir de plusieurs variables explicatives. Pour cela, nous avons construit deux modèles de régression linéaire avec le logiciel R.

3.1 Régression simple : superficie

Nous avons tout d'abord étudié un modèle simple où le loyer est expliqué uniquement par la superficie du logement :

```
mod1 <- lm(loyer ~ superficie, data = data)
```

Le résumé de ce modèle donne les résultats suivants :

- **Intercept** : 169,27 €
- **Coefficient de superficie** : 5,17 € par m²
- **R²** : 0,795 → 79,5% de la variation du loyer est expliquée par la superficie

Interprétation : le loyer augmente en moyenne de 5,17 € pour chaque mètre carré supplémentaire. Ce modèle est simple mais déjà très explicatif.

3.2 Régression multiple : superficie, pièces, quartier

Nous avons ensuite élargi le modèle pour y inclure le nombre de pièces et le quartier :

```
mod2 <- lm(loyer ~ superficie + nb_pieces + quartier, data = data)
```

Ce modèle est plus complet et atteint un **R² de 0,841**, ce qui signifie que 84,1% de la variabilité du loyer est expliquée. Les coefficients principaux sont :

- **Superficie** : 3,75 €/m²
- **Nombre de pièces** : 37,47 €/pièce
- **Quartiers** : certains ont un effet significatif, d'autres non

Interprétation : à superficie et quartier identiques, un logement avec plus de pièces aura tendance à être plus cher.

3.3 Comparaison des deux modèles

Nous avons comparé les deux modèles avec la fonction `anova(mod1, mod2)`. Le test indique que l'ajout des variables `nb_pieces` et `quartier` améliore le modèle, mais pas de manière hautement significative (`p-value` 0,1067). Cela peut s'expliquer par la faible taille de l'échantillon et la représentation inégale des quartiers.

Conclusion : même si la superficie reste la variable principale, le modèle multiple est légèrement plus performant et permet d'ajuster les prédictions selon les spécificités du logement.

4. Validation du modèle via une enquête étudiante

Pour tester la robustesse de notre modèle, nous avons réalisé une enquête complémentaire auprès de **14 étudiants** de notre promotion. Ces étudiants ont accepté de partager des informations sur leur logement actuel à Aurillac : quartier, superficie, nombre de pièces, et loyer réellement payé.

Ces données ont été importées dans R à partir du fichier `Appartement_Etudiant_Promo_nettoye.csv` puis utilisées comme jeu de test. Nous avons ensuite appliqué notre modèle de régression multiple `mod2` pour prédire les loyers correspondants.

4.1 Méthode de validation

1. Importation des données étudiantes.
2. Application du modèle `mod2` avec la fonction `predict()`.
3. Comparaison entre les **loyers réels** et les **loyers prédits**.
4. Calcul de l'erreur pour chaque étudiant.

4.2 Résultats

Voici un extrait du tableau obtenu :

#	Loyer réel (€)	Loyer prédit (€)	Erreur (réel - prédit)
1	300	310,05	-10,05
2	360	300,64	+59,36
3	330	398,90	-68,90
4	400	213,81	+186,19
5	370	280,14	+89,86
6	375	425,20	-50,20
7	0	591,11	-591,11

(Note : les autres lignes sont disponibles en annexe.)

4.3 Erreur quadratique moyenne

Afin de quantifier globalement la qualité de la prédiction, nous avons calculé l'erreur quadratique moyenne (RMSE) entre les valeurs réelles et les valeurs prédites :

$$\text{RMSE} = 186,13 \text{ €}$$

Cela signifie que, en moyenne, notre modèle fait une erreur d'environ 186 € par logement lorsqu'il est appliqué sur des cas extérieurs à l'échantillon d'origine.

Remarque : ce résultat est fortement influencé par un cas particulier (loyer réel à 0 €), ce qui peut être une valeur aberrante ou un logement pris en charge (ex. : Crous, coloc, logement de fonction, etc.).

5. Discussion

L'analyse statistique et les modélisations réalisées nous ont permis de mieux comprendre les facteurs influençant le loyer des logements à Aurillac. Voici les principaux enseignements :

- La **superficie** est la variable la plus fortement corrélée au loyer ($R = 0,892$) et contribue de façon majeure à la prédiction du prix ;
- Le **nombre de pièces** améliore le modèle car il reflète une dimension qualitative de l'espace ;
- Le **quartier** apporte un effet de contexte, mais son influence reste inégale selon les zones et la fréquence des observations.

Cependant, plusieurs **limites** ont été identifiées :

- Le jeu de données est de taille modeste (92 logements), ce qui peut limiter la généralisation du modèle ;
- Certains quartiers sont très peu représentés, ce qui réduit la fiabilité de leurs coefficients dans la régression ;
- Le modèle ne prend pas en compte d'autres variables importantes comme :
 - l'état du logement ;
 - la présence d'un balcon, garage ou ascenseur ;
 - l'étage, l'orientation, ou encore les charges comprises.
- Les données de validation issues de l'enquête montrent des **écarts importants**, notamment pour un logement sans loyer déclaré ou extrêmement bas, ce qui dégrade la RMSE ;
- Enfin, le modèle est purement linéaire, ce qui suppose une relation proportionnelle constante entre les variables, ce qui n'est pas toujours réaliste.

Malgré ces limites, le modèle reste pertinent pour une première estimation, et constitue une base solide pour de futures analyses.

6. Conclusion

Ce projet nous a permis d'appliquer concrètement les méthodes de régression linéaire sur un jeu de données réel dans le cadre de la SAE 2.03. À travers l'analyse de 92 logements à Aurillac, nous avons identifié les principaux facteurs influençant le loyer mensuel.

Parmi les résultats clés :

- La **superficie** est le facteur le plus déterminant, avec une forte corrélation au loyer ;
- L'ajout du **nombre de pièces** et du **quartier** permet d'améliorer la précision des prédictions, même si leur effet reste variable ;
- Le modèle multiple présente une performance satisfaisante avec un $R^2 = 0,841$.

Nous avons également testé le modèle sur un second jeu de données obtenu par une **enquête auprès de 14 étudiants**. Bien que cette validation ait mis en évidence une erreur moyenne de 186 € (RMSE), elle confirme que notre modèle reste globalement cohérent, tout en soulignant ses limites.

Perspectives :

Pour améliorer ce travail, plusieurs pistes peuvent être envisagées :

- Augmenter la taille de l'échantillon et équilibrer la répartition des quartiers ;
- Intégrer de nouvelles variables : état du logement, équipements, proximité des transports, etc. ;
- Tester des modèles non linéaires (arbres de décision, régressions régularisées...) pour capter des effets plus complexes.

Ce projet nous a permis de renforcer nos compétences en manipulation de données, en modélisation statistique et en interprétation critique des résultats. Il constitue une première étape dans la maîtrise de l'analyse prédictive sur données réelles.